## sentiment\_analysis

June 21, 2019

## 1 Objectif

L'objectif de ce TP est d'analyser un corpus de tweets en fonction des opinions exprimées (positif/négatif).

## 2 Import and load data

```
In [1]: import pandas as pd
        import os
        import nltk as nltk
        import re
        from nltk.corpus import wordnet as wn
In [2]: df = pd.read_csv('https://clavel.wp.imt.fr/files/2018/05/testdata.manual.2009.06.14.cs
In [3]: df.columns = ['polarite','id','date','requete','utilisateur','text']
In [4]: df.head(10)
Out [4]:
           polarite
                     id
                                                 date requete
                                                                 utilisateur \
        0
                     3 Mon May 11 03:17:40 UTC 2009
                                                       kindle2
                                                                      tpryan
        1
                     4 Mon May 11 03:18:03 UTC 2009
                                                       kindle2
                                                                      vcu451
                    5 Mon May 11 03:18:54 UTC 2009
                                                       kindle2
                                                                      chadfu
        3
                     6 Mon May 11 03:19:04 UTC 2009
                                                                       SIX15
                                                       kindle2
                     7 Mon May 11 03:21:41 UTC 2009
                                                       kindle2
                                                                    yamarama
        5
                     8 Mon May 11 03:22:00 UTC 2009
                                                       kindle2 GeorgeVHulme
        6
                  0
                     9 Mon May 11 03:22:30 UTC 2009
                                                                     Seth937
                                                           aig
        7
                  4 10 Mon May 11 03:26:10 UTC 2009
                                                                   dcostalis
                                                        jquery
        8
                        Mon May 11 03:27:15 UTC 2009
                                                       twitter
                                                                     PJ_King
                    12 Mon May 11 03:29:20 UTC 2009
                                                                 mandanicole
                                                         obama
          Ostellargirl I loooooooovvvvvveee my Kindle2. ...
          Reading my kindle2... Love it... Lee childs i...
        2 Ok, first assesment of the #kindle2 ...it fuck...
        3 @kenburbary You'll love your Kindle2. I've had...
        4 @mikefish Fair enough. But i have the Kindle2...
```

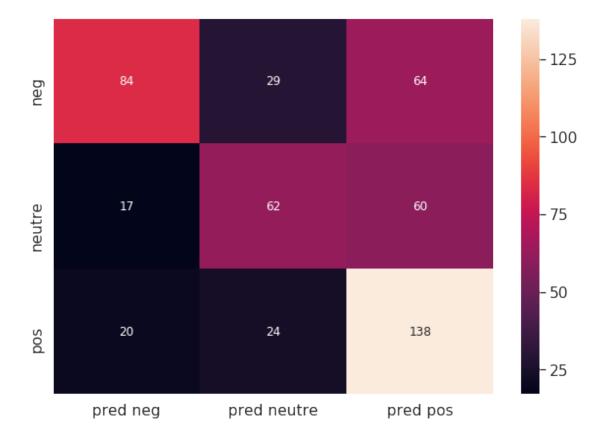
```
5 @richardebaker no. it is too big. I'm quite ha...
        6 Fuck this economy. I hate aig and their non lo...
                               Jquery is my new best friend.
        7
                                               Loves twitter
        9 how can you not love Obama? he makes jokes abo...
In [5]: d = pd.read_csv('/home/b/gitMSBGD/web_data/Lexiques/SlangLookupTable.txt', sep='\t', ex
   .2 Prétraitements
In [6]: def algo1(text):
            text = re.sub(r"http\S+", '', text, flags=re.MULTILINE)
            counts = text.count('0'),text.count('#')
            text = text.replace('0','').replace('#','')
            words = nltk.word_tokenize(text)
            return [word if word not in d.keys() else d[word] for word in words], counts
In [7]: df['nb_0'] = df.text.apply(lambda x: algo1(x)[1][0])
        df['nb_#'] = df.text.apply(lambda x: algo1(x)[1][1])
In [8]: print("Il y a {} @ et {} # dans l'ensemble du corpus".format(df['nb_@'].sum(), df['nb_=
Il y a 128 @ et 52 # dans l'ensemble du corpus
4 3.3 Etiquetage grammatical
In [9]: def algo2(tokens):
            taggedData = nltk.pos_tag(tokens)
            nb_vb = sum([x[1][:2]=='VB' for x in taggedData])
            return taggedData, nb_vb
In [10]: df['nb_vb'] = df.text.apply(lambda x : algo2(algo1(x)[0])[1])
In [12]: print("Il y a {} verbes dans l'ensemble du corpus".format(df['nb_vb'].sum()))
Il y a 1095 verbes dans l'ensemble du corpus
  3.4 v1
In [13]: from nltk.corpus import sentiwordnet as swn
In [14]: nltk.download('sentiwordnet')
[nltk_data] Downloading package sentiwordnet to /home/b/nltk_data...
[nltk_data]
             Package sentiwordnet is already up-to-date!
```

```
Out[14]: True
  On filtre uniquement les mots correspondant à des adjectifs, noms, adverbes et verbes
In [15]: def f(taggedData):
             return [x for x in taggedData if x[1][:2] in ['NN','JJ', 'RB','VB']]
In [16]: def compute_sentiment(pos, neg):
             if pos == neg:
                 return 2
             elif pos>neg:
                 return 4
             else:
                 return 0
In [17]: def score1(taggedData):
             synsets = [wn.synsets(tag[0]) for tag in taggedData]
             neg = [swn.senti_synset(synset[0].name()).neg_score() if synset!=[] else 0 for synset
             pos = [swn.senti_synset(synset[0].name()).pos_score() if synset!=[] else 0 for synset
               print(pos)
             return sum(pos), sum(neg), compute_sentiment(sum(pos), sum(neg))
In [18]: def v1(x):
             return score1(f(algo2(algo1(x)[0])[0]))[2]
In [19]: df['score1'] = df.text.apply(v1)
In [30]: print("Il y a {} tweets postifs correctement détectés".format(np.sum(df[df.polarite==
Il y a 130 tweets postifs correctement détectés
In [38]: np.mean(df.score1 == df.polarite)
Out[38]: 0.5321285140562249
   3.5 v2 negation et modifieurs
In [23]: neg_word_list = pd.read_csv('/home/b/gitMSBGD/web_data/Lexiques/NegatingWordList.txt'
         booster_word_list = pd.read_csv('/home/b/gitMSBGD/web_data/Lexiques/BoosterWordList.ta
In [24]: booster_dict = \{x.split('\t')[0]:x.split('\t')[1] \text{ for } x \text{ in booster_word_list}[0].value.
In [25]: neg_in_pos_tweet = 0
         def score2(taggedData):
             global neg_in_pos_tweet
             boost_idx = [idx+1 for idx, tag in enumerate(taggedData) if tag[0] in booster_dic
             neg_idx = [idx+1 for idx, tag in enumerate(taggedData) if tag[0] in neg_word_list
             synsets = [wn.synsets(tag[0]) for tag in taggedData]
```

```
neg = [swn.senti_synset(synset[0].name()).neg_score() if synset!=[] else 0 for synset
             pos = [swn.senti_synset(synset[0].name()).pos_score() if synset!=[] else 0 for synset
             neg = [neg[i]*2 if i in boost_idx else neg[i] for i in range(len(neg))]
             pos = [pos[i]*2 if i in boost_idx else pos[i] for i in range(len(pos))]
             neg = [pos[i] if i in neg_idx else neg[i] for i in range(len(neg))]
             pos = [neg[i] if i in neg_idx else pos[i] for i in range(len(pos))]
             sentiment = compute_sentiment(sum(pos), sum(neg))
             if sentiment < 4:
                 neg_in_pos_tweet += len(neg_idx)
             return sum(pos), sum(neg), sentiment
In [26]: def v2(x):
             return score2(f(algo2(algo1(x)[0])[0]))[2]
In [27]: df['score2'] = df.text.apply(v2)
In [28]: print("Il y a {} termes négatifs dans les tweets positifs".format(neg_in_pos_tweet))
Il y a 29 termes négatifs dans les tweets positifs
In [32]: print('Il y a {} tweets positifs correctement détectés, {} neutres et {} négatifs'.for
Il y a 131 tweets positifs correctement détectés, 61 neutres et 77 négatifs
In [50]: np.sum(df.score2 == df.polarite)
Out [50]: 269
In [51]: np.mean(df.score2 == df.polarite)
Out[51]: 0.5401606425702812
   3.6 emoticons
In [33]: emoticons = pd.read_csv('/home/b/gitMSBGD/web_data/Lexiques/EmoticonLookupTable.txt',
In [34]: from nltk.tokenize import TweetTokenizer
         tokenizer= TweetTokenizer()
         def algo1bis(text):
             text = re.sub(r"http\S+", '', text, flags=re.MULTILINE)
             counts = text.count('@'),text.count('#')
             text = text.replace('0','').replace('#','')
             words = tokenizer.tokenize(text)
             return [word if word not in d.keys() else d[word] for word in words], counts
```

```
In [35]: emo_count = 0
         def score3(taggedData):
             global emo_count
             emo = [emoticons[tag[0]] for idx, tag in enumerate(taggedData) if tag[0] in emoti-
              print(emo)
             emo_count += len(emo)
             boost_idx = [idx+1 for idx, tag in enumerate(taggedData) if tag[0] in booster_dic
             neg_idx = [idx+1 for idx, tag in enumerate(taggedData) if tag[0] in neg_word_list
             synsets = [wn.synsets(tag[0]) for tag in taggedData]
             neg = [swn.senti_synset(synset[0].name()).neg_score() if synset!=[] else 0 for synset
             pos = [swn.senti_synset(synset[0].name()).pos_score() if synset!=[] else 0 for synset
             neg = [neg[i]*2 if i in boost_idx else neg[i] for i in range(len(neg))]
             pos = [pos[i] *2 if i in boost_idx else pos[i] for i in range(len(pos))]
               print(pos)
             neg = [pos[i] if i in neg_idx else neg[i] for i in range(len(neg))]
             pos = [neg[i] if i in neg_idx else pos[i] for i in range(len(pos))]
             pos, neg = sum(pos)+sum([x>0 for x in emo]), sum(neg)+sum([x<0 for x in emo])
             return pos, neg, compute_sentiment(pos, neg)
In [37]: def v3(x):
             return score3(f(algo2(algo1bis(x)[0])[0]))[2]
In [38]: df['score3'] = df.text.apply(v3)
In [40]: print('Il y a {} emoticons présents dans le corpus'.format(emo_count))
Il y a 56 emoticons présents dans le corpus
In [41]: print('Il y a {} tweets positifs correctement détectés, {} neutres et {} négatifs'.fo
Il y a 138 tweets positifs correctement détectés, 62 neutres et 84 négatifs
In [59]: np.sum(df.score3 == df.polarite)
Out[59]: 284
In [60]: np.mean(df.score3 == df.polarite)
Out [60]: 0.570281124497992
In [42]: from sklearn.metrics import confusion_matrix
In [44]: import seaborn as sn
         import pandas as pd
         import matplotlib.pyplot as plt
         labels=['neg','neutre','pos']
         cm = confusion_matrix(df.polarite, df.score3)
```

Out[44]: <matplotlib.axes.\_subplots.AxesSubplot at 0x7f5ad56f8710>



## 8 V4

J'ai d'abord commencé par traiter le cas des lettres répétées: je me suis rendu qu'un mot comme loooooovvvve n'etait pas reconnu par nltk. J'ai donc décidé de remplacer toutes répétitions de 3 lettres ou plus par une seule.

Cela me permet de correctement détecté 2 tweets supplémentaires. J'ai essayé d'autres choses comme gardé uniquement le score de l'emoticon s'il y en a une dans le tweet, de comparer le nombre de mots avec un score négatifs avec le nombre de mots ayant un score positif mais cela n'a pas permis d'améliorer, tout comme l'ajout du stemming. J'ai ensuite essyé d'entrainer un modèle après avoir appliqué une TfidfVectorizer:

Ce qui permet d'ameliorer la prediction de plus de 10%.